

Ecuaciones del Indicador IS_d

Indicador de Singularidad Documental

Blázquez Ochando, M. · Ovalle Perandones, M.A. · Prieto Gutiérrez, J.J.
Universidad Complutense de Madrid

2025

Ecuación (1) — Estructura general del indicador

$$IS_d = \alpha \cdot O_d + (1 - \alpha) \cdot I_d \quad \alpha \in [0, 1] \quad (1)$$

Donde O_d es el componente de originalidad textual, I_d el componente de impacto bibliométrico y α el parámetro de ponderación.

Ecuación (2) — Normalización de O_d

$$O_d = \min\left(\frac{O_d^{raw}}{P_{99}(O^{raw})}, 1\right) \quad (2)$$

Donde $P_{99}(O^{raw})$ es el percentil 99 de los valores O_d^{raw} en el corpus.

Ecuación (3) — Originalidad textual bruta O_d^{raw}

$$O_d^{raw} = \frac{\sum_{i \in \Omega_d} S_i \cdot \log(1 + f_i^{doc})}{|\Omega_d| \cdot \log\left(1 + \frac{T_d}{|\Omega_d|}\right) + \varepsilon} \quad (3)$$

Donde:

- Ω_d = conjunto de n-gramas únicos presentes en el documento d
- $|\Omega_d|$ = número de n-gramas únicos (cardinal del conjunto)
- f_i^{doc} = frecuencia absoluta del n-grama i en el documento d
- T_d = total de n-gramas extraídos del documento d (con repetición)
- $\varepsilon = 10^{-6}$ = constante de suavizado numérico

Ecuación (4) — Peso de singularidad S_i

$$S_i = \underbrace{\log\left(\frac{C+1}{cd_i+0,5}\right)}_{\text{IDF de Robertson}} \cdot \underbrace{\frac{1}{1+\log(1+f_i^{corpus})}}_{\text{penalización de frecuencia (BM25)}} \quad (4)$$

Donde:

- C = número total de documentos en el corpus
- cd_i = número de documentos del corpus que contienen el n-grama i
- f_i^{corpus} = frecuencia total del n-grama i en todo el corpus

Ecuación (5) — Impacto bibliométrico normalizado I_d

$$I_d = \frac{\log(1+C_d)}{\log(1+C_{max})} \quad (5)$$

Donde C_d es el número de citas recibidas por el documento d y C_{max} es el máximo de citas en el corpus ($C_{max} = 53.982$ en calcia.db). Se verifica que $I_d \in [0, 1]$ exactamente: $I_d = 0$ si $C_d = 0$; $I_d = 1$ si $C_d = C_{max}$.

Ecuación (α^*) — Criterio objetivo de calibración

$$\alpha^* = \arg \min_{\alpha \in [0,1]} |\text{skew}(\alpha \cdot O_d + (1-\alpha) \cdot I_d)| \quad (6)$$

Sobre calcia.db: $\alpha^* = 0,692 \approx 0,70$, con $|\text{skew}| = 0,00058$ (mínimo global). La T de Kendall de los deciles permanece igual a 1,0 para todo $\alpha \in [0; 0,90]$.